

UNIVERSIDADE DE COIMBRA
FACULDADE DE CIÊNCIAS E TECNOLOGIA
DEPARTAMENTO DE ENGENHARIA INFORMÁTICA

Engenharia de Características para Aprendizagem
Computacional

Classificação de Atividades Humanas

Relatório Integrado: Meta 1 e Meta 2

Autor: João Natálio (2023205576)

Coimbra
Dezembro de 2025

Sumário Executivo

Este relatório documenta a implementação de uma *pipeline* completa de Ciência de Dados para o reconhecimento de atividades humanas (HAR) utilizando o dataset FORTH-TRACE. O projeto foi desenvolvido em duas fases complementares.

Na **Meta 1**, realizou-se a caracterização estatística dos dados, limpeza de ruído e engenharia de características manuais. Os resultados mostraram que métodos como o Z-Score ($k = 4.0$) são eficazes na remoção de outliers (0.79%) e que variáveis baseadas na energia do sinal (e.g., *acc_y_spec_energy*) são altamente discriminantes.

Na **Meta 2**, o sistema foi expandido com técnicas de *Deep Learning* (embeddings) e aumento de dados (SMOTE). A avaliação comparativa revelou que a abordagem clássica (**Features Manuais + PCA**) superou as representações latentes pré-treinadas, atingindo um **F1-score de 0.79** em validação intra-sujeito. O modelo final, otimizado para generalização, utiliza PCA com 37 componentes e um classificador k-NN Ponderado.

Conteúdo

1	Introdução	3
2	Meta 1: Análise Exploratória e Engenharia de Features	3
2.1	Deteção de Outliers	3
2.2	Significância Estatística	4
2.3	Extração e Seleção de Features	4
3	Meta 2: Embeddings, Data Augmentation e Validação	4
3.1	Data Augmentation (SMOTE)	5
3.2	Features Manuais vs. Embeddings (HARNet5)	5
3.2.1	Resultados Experimentais	5
3.3	Modelo Final e Deployment	6
4	Conclusão	6

1 Introdução

O reconhecimento de atividades humanas (HAR) a partir de sensores *wearable* apresenta desafios únicos, como a variabilidade entre utilizadores e a presença de ruído nos sensores. Este projeto visou construir um sistema robusto capaz de classificar atividades (e.g., andar, sentar, subir escadas) processando dados de acelerómetros, giroscópios e magnetómetros.

O trabalho divide-se em:

- **Meta 1 (Análise e Features):** Focada na compreensão dos dados, deteção de anomalias e extração manual de descritores físicos.
- **Meta 2 (Modelação e Validação):** Focada na comparação entre conhecimento humano (features manuais) e representações automáticas (embeddings), testando a capacidade de generalização do sistema.

Todos os testes focaram-se no **Dispositivo 2 (Pulso Direito)**, por ser uma localização representativa para a captura de movimentos globais do corpo.

2 Meta 1: Análise Exploratória e Engenharia de Features

Nesta fase, o objetivo foi transformar os dados brutos (781.822 amostras no Dispositivo 2) num conjunto de dados limpo e informativo.

2.1 Deteção de Outliers

Foram implementadas e comparadas três abordagens para identificar ruído ou movimentos anómalos:

- **Método de Tukey (1.5 IQR):** Analisa a dispersão estatística.
- **Z-Score:** Analisa o desvio padrão em relação à média.
- **K-Means (Multivariável):** Agrupa dados em clusters e identifica pontos distantes dos centroides.

Resultados e Discussão: O método de Tukey revelou-se demasiado sensível, marcando cerca de 15% a 19% das amostras como *outliers* em atividades de transição (ex: Atividade 9, Sit->Stand). Isto é esperado, pois transições geram picos naturais de aceleração.

O método **Z-Score** foi mais robusto. Ao aumentar o limiar k , a percentagem de outliers caiu drasticamente:

- $k = 3.0$: 2.15% de outliers.
- $k = 4.0$: **0.79% de outliers**.

Optou-se por $k = 4.0$ para preservar a integridade de movimentos intensos.

A análise multivariável com **K-Means (3 clusters)** identificou 3 regimes de movimento distintos (Repouso, Moderado, Intenso), classificando 4.17% das amostras como anômalas, o que corrobora a existência de ruído, mas confirma a qualidade geral dos dados.

2.2 Significância Estatística

Antes de extrair *features*, validou-se se os dados brutos tinham poder discriminante.

- **Normalidade:** O teste Kolmogorov-Smirnov confirmou que as distribuições não são normais ($p = 0.0$).
- **Discriminação:** O teste Kruskal-Wallis apresentou valores de H extremamente elevados (ex: $H \approx 573.434$ para o giroscópio), confirmando que as magnitudes dos sensores variam significativamente entre atividades.

2.3 Extração e Seleção de Features

Segmentaram-se os dados em janelas de 5 segundos, extraíndo-se 180 *features* (temporais e espectrais). Para reduzir a dimensionalidade, compararam-se dois métodos de seleção: **Fisher Score** e **ReliefF**.

Resultados da Seleção:

- O **Fisher Score** privilegiou *features* de energia pura, como **f26** (*acc_y_spec_energy*).
- O **ReliefF**, que considera interações entre variáveis, também destacou a **f26**, mas deu peso elevado a variáveis de dispersão como **f56** e **f86**.

A feature **f26** (Energia Espectral do Eixo Y) apareceu consistentemente no topo, indicando que a "quantidade de movimento vertical/lateral" é o indicador mais forte da atividade.

Na redução via **PCA (Meta 1)**, verificou-se que apenas ****15 componentes**** explicavam cerca de 75.6% da variância dos dados, permitindo uma compressão eficiente.

3 Meta 2: Embeddings, Data Augmentation e Validação

Nesta fase, procurou-se superar as limitações da engenharia manual e testar o sistema em cenários reais.

3.1 Data Augmentation (SMOTE)

Devido ao desequilíbrio de classes (ex: 157k amostras de "Stand" vs 43k de "Stairs"), implementou-se o SMOTE. A visualização das amostras geradas (Participante 3, Atividade 4) confirmou que os dados sintéticos respeitam a geometria do espaço de características original, enriquecendo o treino sem introduzir artefactos.

3.2 Features Manuais vs. Embeddings (HARNet5)

O ponto central da Meta 2 foi comparar:

1. **Features Manuais:** O *set* de 180 variáveis criado na Meta 1.
2. **Embeddings:** Vetores de 512 dimensões extraídos automaticamente pela rede neuronal HARNet5.

Para tal, utilizaram-se duas estratégias de divisão (*split*):

- **Within-Subject:** Treino e teste no mesmo utilizador (personalização).
- **Between-Subjects:** Teste em utilizadores nunca vistos (generalização).

3.2.1 Resultados Experimentais

A tabela abaixo resume os resultados de Macro-F1 (média de 5 repetições):

Tabela 1: Comparação de Desempenho (Macro-F1)

Dataset	Estratégia	Melhor Versão	Macro-F1
Embeddings	Within-Subject	All Features	0.69
Embeddings	Between-Subjects	ReliefF	0.46
Features Manuais	Within-Subject	PCA (90% var)	0.79
Features Manuais	Between-Subjects	PCA (90% var)	0.60

Discussão:

1. **Vitória das Features Manuais:** O melhor resultado global (F1=0.79) foi obtido com as Features Manuais + PCA. Isto sugere que, para estes sensores específicos, as métricas físicas (energia, frequência) capturam melhor a essência do movimento do que os *embeddings* genéricos da HARNet5.
2. **O Papel do PCA:** Enquanto o PCA melhorou o desempenho das Features Manuais (de ≈ 0.70 para 0.79) ao remover ruído, prejudicou os *embeddings*. Os *embeddings* já são representações compactas; comprimi-los mais resultou em perda de informação.

3. **Desafio da Generalização:** No cenário *Between-Subjects*, todas as performances caíram. No entanto, as Features Manuais mantiveram-se robustas ($F1=0.60$), enquanto os Embeddings colapsaram ($F1=0.46$). Isto indica que a rede neuronal pode estar a fazer *overfitting* a características específicas dos utilizadores de treino, falhando em generalizar para novos indivíduos.

3.3 Modelo Final e Deployment

Com base nestes resultados, a *pipeline* final para *deployment* foi construída usando:

- **Input:** Janela bruta (256x9).
- **Processamento:** Features Manuais $\rightarrow$ Standard Scaler $\rightarrow$ PCA (37 componentes para 90% variância).
- **Classificador:** k-NN ($k = 7$).

Como melhoria final ("Go Further"), implementou-se um **Weighted k-NN**. Esta alteração simples subiu o F1 no conjunto de teste para **0.6929**, melhorando a distinção entre atividades dinâmicas semelhantes (como "Walk" vs "Walk and Talk").

4 Conclusão

O desenvolvimento deste projeto permitiu validar na prática os conceitos teóricos de Engenharia de Características.

Conclui-se que a **limpeza de dados na Meta 1** (Z-score, remoção de ruído) foi fundamental para a estabilidade dos modelos na Meta 2. Além disso, demonstrou-se que nem sempre o *Deep Learning* (*embeddings*) é a solução superior "fora da caixa"; a engenharia de características clássica, guiada por conhecimento de domínio (física do movimento) e redução de dimensionalidade (PCA), produziu resultados mais precisos e, crucialmente, mais robustos a novos utilizadores.

O sistema final entregue combina o melhor dos dois mundos: uma base de dados bem curada e um modelo otimizado para generalização.